

Tugas Besar Aljabar Linear

JONATHAN DELEN HOSEA (10122054), DZUBYAN ILMAN RAMADHAN (10122010),
RACHMA NURHIDAYAH (10122037), ADHITYO RAFAEL ANDY SIGIT (10122020),
HENDRI SAPUTRA (10122024)

Institut Teknologi Bandung

Daftar Isi

I	Pendahuluan	1
II	Latar Belakang Matematis	1
III	Definisi Masalah	1
IV	Usulan Solusi	2
V	Analisis dan Interpretasi	3
VI	Kesimpulan dan Saran	4
	Lampiran	4
	Referensi	4

Daftar Gambar

1	Wajah Rata-rata & 6 <i>Eigenfaces</i> Pertama.....	3
2	Perbandingan Gambar Asli (Kiri) dengan Hasil Rekonstruksi $k = 10$ (Tengah) dan $k = 20$ (Kanan).....	3

Daftar Tabel

1	Hasil Akurasi Pengenalan Wajah.....	3
---	-------------------------------------	---

Tugas Besar Aljabar Linear

I. PENDAHULUAN

Gambar digital, termasuk citra wajah, merupakan objek data yang berdimensi tinggi. Bahkan, sebuah foto wajah hitam-putih berukuran 92x112 piksel saja sudah memuat 10.304 nilai piksel yang berbeda-beda. Tingginya dimensi ini menjadi tantangan tersendiri bagi sebuah sistem pengenalan wajah.

Namun demikian, manusia sebenarnya dapat mengenali wajah dengan mudah. Dengan kata lain, sebagian besar variasi piksel sebenarnya tidak relevan dan informasi mengenai identitas dapat ditemukan dimensi yang jauh lebih rendah.

Oleh karena itu, tujuan dari proyek ini adalah menemukan representasi ringkas untuk sekumpulan gambar wajah, yang berupa satu set gambar basis yang mampu menangkap mode variasi utama dari banyak wajah dengan mengabaikan detail-detail yang tidak relevan.

II. LATAR BELAKANG MATEMATIS

Metode Eigenfaces sangat bergantung pada teknik fundamental dalam aljabar linear yang disebut Singular Value Decomposition (SVD). SVD menyatakan bahwa setiap matriks A berukuran $d \times N$ dapat difaktorkan menjadi tiga matriks, yaitu:

$$A = U\Sigma V^T$$

di mana:

- U , yaitu matriks ortogonal $d \times d$ yang kolom-kolomnya disebut vektor singular kiri. Di sini, U menjadi *eigenfaces* atau basis-basis ortonormal yang mewakili pola variasi utama pada data wajah.
- Σ , yaitu matriks diagonal $d \times N$ yang elemen diagonalnya adalah nilai-nilai singular ($\sigma_1, \sigma_2, \dots$) non negatif terurut dari matriks A . Besar tiap nilainya

merepresentasikan besarnya kontribusi *eigenface* yang bersesuaian dalam menyusun gambar asli.

- V^T , yaitu transpose matriks ortogonal V berukuran $N \times N$ yang kolom-kolomnya adalah vektor singular kanan.

Dalam sistem pengenalan wajah, SVD mampu memberikan aproksimasi matriks peringkat rendah (low-rank approximation) yang optimal. Aproksimasi terbaik dari matriks A dengan matriks lain yang memiliki peringkat lebih rendah, k misalnya ($k < \text{rank}(A)$) dapat diperoleh dengan mengambil k nilai singular pertama beserta vektor-vektor singular yang bersesuaian. Dengan kata lain, aproksimasi peringkat- k dapat dihitung dengan rumus:

$$A_k = U_k \Sigma_k V_k^T$$

di mana:

- U_k matriks berisi k kolom pertama dari U
- Σ_k matriks diagonal $k \times k$ yang berisi k nilai singular pertama
- V_k^T matriks berisi k baris pertama dari V^T

Dengan memilih nilai k yang jauh lebih kecil dari dimensi asli ($k \ll d$), setiap wajah dapat direpresentasikan dengan ringkas hanya dengan k koefisien, sehingga berhasil mereduksi dimensi data secara drastis sambil tetap mempertahankan informasi esensial yang diperlukan untuk membedakan identitas.

III. DEFINISI MASALAH

Masalah utama dalam tugas ini berakar pada representasi citra wajah digital sebagai objek berdimensi tinggi, yang dapat menjadi tantangan tersendiri bagi sistem pengenalan wajah, yaitu:

- Curse of Dimensionality, yang mana perbedaan antara dua vektor gambar lebih banyak dipengaruhi oleh variasi non-identitas (perubahan pencahayaan, latar belakang, atau pergeseran posisi yang minor). Akibatnya, sulit untuk mengklasifikasikan identitas secara akurat jika hanya membandingkan vektor piksel yang mentah.
- Biaya komputasi dan penyimpanan, yang mana menyimpan dan memproses ribuan vektor berdimensi tinggi secara langsung membutuhkan sumber daya komputasi dan memori yang besar sehingga menjadi kendala signifikan untuk aplikasi yang berjalan secara real-time atau pada perangkat keras dengan spesifikasi terbatas.

Dengan demikian, definisi masalahnya adalah bagaimana cara mengatasi kendala-kendala tersebut dengan menemukan sebuah representasi wajah berdimensi rendah yang efisien, tetapi tetap mampu mempertahankan informasi esensial yang diperlukan untuk melakukan klasifikasi identitas secara akurat.

IV. USULAN SOLUSI

Untuk mengatasi kendala-kendala tersebut, digunakanlah metode *eigenfaces* yang memanfaatkan SVD untuk mereduksi dimensi data. Langkah-langkahnya, yaitu:


- Vektorisasi Citra: setiap gambar wajah berukuran 92×112 piksel diratakan (flatten) menjadi vektor kolom tunggal, x_i , yang berada dalam ruang $\mathbb{R}^{10304}$.
 - Pemusatan Data: wajah rata-rata, μ , dihitung dari seluruh set gambar training. Selanjutnya, setiap vektor gambar training x_i dikurangi dengan μ tersebut untuk menghasilkan matriks data terpusat, $X_c = [x_i - \mu]$. Langkah ini bertujuan menghilangkan fitur-fitur
- umum pada semua wajah dan berfokus pada variasi unik antar wajah.
- SVD: diterapkan pada matriks terpusat X_c dengan fungsi `numpy.linalg.svd` dan parameter `full_matrices = False`. Proses ini akan menghasilkan matriks U , di mana kolom-kolomnya adalah *eigenfaces* yang membentuk basis ortonormal untuk “ruang wajah”.
 - Proyeksi ke Ruang Wajah: untuk mereduksi dimensi, seluruh gambar diproyeksikan ke ruang wajah berdimensi k yang dibentuk oleh k *eigenfaces* pertama, yang mana untuk tugas ini digunakan $k = 10$ dan $k = 20$. Proyeksi dilakukan dengan menghitung vektor koordinat $z = U_k^T (x - \mu)$, di mana U_k merupakan matriks berisi k *eigenfaces* pertama.
 - Klasifikasi Nearest Neighbour: setiap gambar testing yang diproyeksikan ke ruang $\mathbb{R}^k$ diklasifikasikan dan label identitasnya ditentukan dengan mencari gambar training yang memiliki jarak *Euclidean* (jarak garis lurus antar 2 titik dalam sebuah ruang) terdekat dalam ruang tersebut. Wajah *training* dengan jarak *Euclidean* terkecil dengan wajah *testing* dianggap sebagai identitas paling cocok (prediksi).
 - Perhitungan Akurasi: akurasi keseluruhan dari sistem dihitung untuk masing-masing nilai k dengan membandingkan label hasil prediksi dari langkah klasifikasi dengan label sebenarnya dari set data testing.
 - Rekonstruksi Wajah: untuk mengevaluasi kualitas informasi, satu gambar sampel direkonstruksi dari representasi berdimensi rendahnya. Proses ini dilakukan untuk $k = 10$ dengan menggunakan rumus:

$$\hat{x} = U_k U_k^T (x - \mu) + \mu$$

V. ANALISIS DAN INTERPRETASI

Pada percobaan ini dihasilkan 3 output utama, yaitu:

- Galeri *eigenface*



Gambar 1. Wajah Rata-rata & 6 *Eigenfaces* Pertama
Gambar ini menampilkan wajah rata-rata (μ) yang dihitung dari set data training beserta 6 *eigenfaces* pertama dengan nilai singular terbesar. *Eigenfaces* tersebut merepresentasikan komponen-komponen varian utama dalam data.

- Akurasi klasifikasi

Akurasi pengenalan wajah diuji dengan 2 nilai k berbeda, yaitu $k = 10$ dan $k = 20$. Hasil akurasi dari klasifikasi *Nearest Neighbour* pada set data testing disajikan pada tabel berikut.


Tabel 1. Hasil Akurasi Pengenalan Wajah

k	Akurasi (%)
10	100.00
20	100.00

- Rekonstruksi wajah

Untuk menilai kualitas informasi yang dipertahankan setelah reduksi dimensi, satu gambar dari set testing dibuat

rekonstruksinya dengan menggunakan $k = 10$ dan $k = 20$ *eigenfaces*.



Gambar 2. Perbandingan Gambar Asli (Kiri) dengan Hasil Rekonstruksi $k = 10$ (Tengah) dan $k = 20$ (Kanan)

Berdasarkan ketiga output tersebut, dapat diuraikan beberapa analisis.

Mean face secara visual merepresentasikan fitur-fitur yang paling umum atau rata-rata dari seluruh gambar training. Hasilnya adalah wajah yang terlihat generik, simetris, dan tanpa ekspresi yang jelas. Hal ini dikarenakan semua fitur unik dari setiap individu (seperti senyuman, kacamata, atau bentuk wajah yang spesifik) telah "dirata-ratakan" sehingga menjadi kabur. Sementara itu, *eigenfaces* yang ditampilkan merupakan komponen-komponen variasi utama dari *mean face* tersebut, contohnya adalah perubahan pencahayaan dan ekspresi yang minor.

Hasil pada Tabel 1 menunjukkan bahwa akurasi pengenalan wajah mencapai nilai 100.00%, baik untuk $k = 10$ maupun $k = 20$. Tingginya nilai tersebut kemungkinan besar dipengaruhi oleh beberapa faktor. Pertama, lingkup proyek yang terbatas (hanya 6 subjek) membuat tugas klasifikasi menjadi lebih sederhana. Kedua, dataset AT&T yang digunakan sangat terkontrol atau "bersih" sehingga dapat meminimalkan *noise* pada klasifikasi. Hasil tersebut mendemonstrasikan bahwa dengan kondisi data yang ideal, 10 komponen *eigenfaces* saja sudah cukup untuk menangkap variasi esensial dan menciptakan model yang dapat memisahkan setiap individu dengan sempurna. Karenanya, tidak ada peningkatan akurasi yang signifikan dari $k = 10$ ke $k = 20$ seperti pada Gambar 2.

VI. KESIMPULAN DAN SARAN

Berdasarkan analisis yang telah dilakukan, dapat disimpulkan bahwa proyek ini berhasil menemukan representasi ringkas untuk data wajah dengan menggunakan metode *eigenfaces* yang diturunkan dari SVD. Pada Gambar 2 dapat dilihat bahwa representasi yang terkompresi dengan $k = 10$ mampu memulihkan citra wajah dengan keakuratan yang sangat tinggi. Hal ini menunjukkan bahwa metode yang digunakan mampu menangkap mode variasi utama sambil mengabaikan detail-detail yang tidak relevan.

Selain itu, akurasi klasifikasi yang mencapai 100% pada ruang wajah yang terkompresi membuktikan bahwa metode ini mampu memisahkan individu dengan baik. Meskipun dimensi data telah direduksi secara drastis dari 10.304 ke 10, informasi krusial untuk identifikasi tetap terjaga dengan baik.

Dengan tercapainya kedua tujuan tersebut, dapat disimpulkan bahwa dekomposisi nilai singular (SVD) sangat efektif dan efisien untuk mengatasi tantangan data yang berdimensi tinggi dalam masalah sistem pengenalan wajah.

Meskipun metode ini menunjukkan keberhasilan absolut pada dataset yang digunakan, penting untuk dicatat bahwa eksperimen ini dilakukan dalam lingkup yang terbatas (6 subjek). Karena itu, disarankan untuk diadakan adanya penelitian lebih lanjut dengan menguji metode ini pada dataset yang lebih besar dan lebih beragam untuk menguji ketahanan dan generalisasi dari model. Selain itu, penggunaan nilai k yang kecil (misalnya antara 10-20) sangat direkomendasikan karena telah terbukti memberikan hasil yang maksimal dengan biaya komputasi yang minimal.

LAMPIRAN

Seluruh kode yang digunakan dalam proyek ini dijalankan pada Google Colab dan terlampir pada link berikut.
<https://bit.ly/MiniProjectLinearAlgebra>

Dataset yang digunakan pada proyek ini, yaitu att_faces terlampir pada link berikut.
https://bit.ly/Dataset-att_faces

Slide yang digunakan untuk presentasi terlampir pada link berikut.
<https://bit.ly/ESVDPresentation>

REFERENSI

- [1] M. Turk and A. Pentland, "Eigenfaces for recognition," *Journal of Cognitive Neuroscience*, vol. 3, no. 1, pp. 71-86, 1991.
- [2] AT&T Laboratories Cambridge, "The Database of Faces," [Online]. Available: <https://www.cl.cam.ac.uk/research/dtg/attarchive/facedatabase.html>. [Diakses: 5 Juli 2025].